



# Computação Paralela

## Tipos de Paralelismo

Paralelismo por *Bit*

Paralelismo por Pipelining

Paralelismo por *Functional Units* (FU)

Paralelismo por Processos ou *Threads*

## Processadores *Multicore*

Arquitetura

## Conceitos Básicos

## Organização de Memória

## Execução

## Arquiteturas

Single Instruction, Single Data

Single Instruction, Multiple Data

Multiple Instruction, Multiple Data

## Implementação

### Modelos

Modelo Máquina

Modelo Arquitetural

Modelo Computacional

Modelo de Programação

## Paralelização de Programas

## Padrões

Fork-Join

Parbegin-Parend

SPMD e SIMD

Master-Slave e Master-Worker

Client-Server

Pipelining

Producer-Consumer

## Processos

## Threads

Estados

Controlo de Execução

Java


# Tipos de Paralelismo

## Paralelismo por *Bit*

- Relaciona-se com o aumento na capacidade de processamento de dados;
- **Mais bits permitem efetuar operações mais complexas de uma forma mais imediata.**

## Paralelismo por Pipelining

- O pipeline pode ser comparado a uma linha de montagem:
  - Cada fase da linha poderá operar em paralelo caso não existam dependências entre as instruções;
  - Um *pipeline* eficiente possui instruções com durações semelhantes;
  - O *throughput* de um *pipeline* é o número de instruções finalizadas por unidade de tempo.



## Paralelismo por *Functional Units (FU)*

- Existem várias unidades funcionais (ALU e FPU) independentes;
  - Estas unidades executam tarefas independente e paralelamente;
  - O número de FU a utilizar paralelamente poderá ser limitado consoante a dependência dos dados;

- A sua utilização irá aumentar significativamente a complexidade do circuito.


## Paralelismo por Processos ou *Threads*

- Implica a utilização de sistemas *multicore/multiprocessor*;
  - Cada *core* acede à mesma memória partilhada;
  - Cada *core* executa um só fluxo;
  - Implica a utilização de técnicas de programação paralelas.

## Processadores *Multicore*


### Arquitetura

- **Design hierárquico:** várias cores partilham várias *caches*, organizadas em forma de árvore, com o seu tamanho a aumentar desde as folhas até à raiz;




Arquitetura de sistemas *multicore*.

- **Design em *pipeline*:** os dados são processados por elemento de processamento organizados em formato de *pipeline*; os dados são transferidos entre os *cores* de forma sucessiva até deixarem a unidade de processamento.



Arquitetura em *pipeline*.

- **Design em rede:** os *cores* de um processador e respectivas caches e memórias estão ligadas através de uma rede sob a qual ocorre a transferência de dados.



## Conceitos Básicos

- A **decomposição da aplicação em *tasks*** é essencial para o design de um sistema paralelo;
  - O tamanho de cada *task* designa-se por **granularidade**;
  - As *tasks* são programadas através de processos ou *threads*, atribuídos posteriormente a diferentes *cores*;
- **Scheduling.**

## Organização de Memória

- As *tasks* partilham “conhecimento” de maneiras distintas:

- **Memória Partilhada:**
  - Pode ser acedida por todos os *cores*;
  - É feita através de R/W em variáveis partilhadas;
    - O acesso a esta memória tem de ser sincronizada.
- **Memória Distribuída:**
  - Cada processo ou *thread* tem a sua memória privada;
  - A partilha de informação ocorre com a troca de mensagens.

## Execução

- O tempo de execução de um programa paralelo deverá ser menor que a execução das mesmas tarefas de forma sequencial;
- Existirão sempre *idle times* durante uma execução paralela:
  - O CPU está à espera do output de um evento;
  - Um **load balancing** equilibrado tenta mitigar os tempos de espera de um programa paralelo: distribuição de tarefas de maneira igual por todos os *cores*.


## Arquiteturas

### Single Instruction, Single Data

A sequential computer which exploits no parallelism in either the instruction or data streams. Single control unit (CU) fetches a single instruction stream (IS) from memory. The CU then generates appropriate control signals to direct a single processing element (PE) to operate on a single data stream (DS) i.e., one operation at a time


- Computador sequencial que não explora o paralelismo ao nível das instruções nem dos *stream* de dados;
- Uma única unidade de controlo (*control unit*, CU) carrega uma única instrução de memória;
- A CU gera os sinais de controlo apropriados para que uma única unidade de processamento (*processing element*, PE) opere sobre sobre uma único fluxo de

dados (*data stream*, DS), i.e uma operação de cada vez.




## Single Instruction, Multiple Data

- Uma única instrução é simultaneamente aplicada a vários DS;
- As instruções podem ser executadas sequencialmente (e.g. via *pipelining* ou em paralelo por múltiplas FU).
- Multiple Instruction, Single Data




- Várias instruções operam sobre um único fluxo de dados;
- Sistemas deste tipo devem concordar no *output*/resultado;
- Arquitetura pouco comum, utilizada para tolerância de falhas.



## Multiple Instruction, Multiple Data

- Vários CPU autónomos executam, simultaneamente, diferentes instruções em DS diferentes;
- Estas arquiteturas tipicamente incluem **sistemas distribuídos**.



## Implementação

### Modelos

- Podemos diferenciar os modelos para computação paralela de acordo com o seu nível de abstração.

### Modelo Máquina

- Descreve o *hardware* e o SO (e.g. registos e *buffers*);
- Linguagens *assembly* usam estes tipos de modelos.

### Modelo Arquitetural

- Descreve ligações entre processos, organização e sincronização de memória, bem como se as instruções são executadas por SIMD ou MIMD.

## Modelo Computacional

- Fornece funções de custo para o tempo necessário para a execução do algoritmo;
- Modelo analítico para o desenho e avaliação de um algoritmo paralelo.

## Modelo de Programação

- Representa a visão de um programador de um determinado sistema paralelo;
- **Deverá fornecer um mecanismo para o programador especificar um sistema paralelo:** especificar que operações são executadas em paralelo.
  - Como uma sequência de instruções aritméticas ou lógicas;
  - Conjuntos de *statements*;
  - Uma função ou método que contem diversos *statements*.

## Paralelização de Programas

- Necessário considerar as estruturas de controlo e dependências de dados;
- **Garantir que a versão paralela do programa retorna o mesmo resultado para todos os inputs possíveis;**

## Padrões

- Criação de processos e *threads*:
  - **Estaticamente:** número fixo de processos ou *threads* é criado quando o programa é iniciado, e finalizados quando o programa finaliza;
  - **Dinamicamente:** estes elementos poderão ser criados de forma arbitrária durante a execução do programa.

## Fork-Join

- Uma thread  $T$  cria um conjunto de *threads* filhas  $T_1, \dots, T_n$ :
  - Trabalham em paralelo e executam uma ou mais instruções/funções.



- $T$  pode executar a mesma parte ou outra qualquer do programa;
- O comando `join` é utilizado para  $T$  esperar pelo resultado de  $T_1, \dots, T_n$ .

## Parbegin-Parend

- Na construção, são definidas uma série de instruções que deverão ser executadas em paralelo;
- Quando um programa chega a um comando `parbegin-parend`, um conjunto de *threads* é criado e as *statements* são atribuídas às mesmas;
- O restante prorama só é executado depois de todas as *threads* finalizarem as operações.

## SPMD e SIMD

- Utilizam um número fixo de *threads*;
- **SIMD**: a mesma instrução é executada de forma síncrona por diferentes *threads* em diferentes conjuntos de dados;
- **SPMD**: diversas *threads* trabalham de forma assíncrona entre sí, podendo executar diferentes partes do programa.

## Master-Slave e Master-Worker

- A *thread master* é responsável pela execução do programa (cria *workers* em diferentes partes do programa para realizar operações paralelas).

## Client-Server

- Utilizado em sistemas distribuídos;
- Vários sistemas clientes comunicam com um main-frame que fornece acesso distribuído a uma base de dados;
- Devem ser criadas diversas *threads client*, que geram algum tipo de pedido ao *server*.

## Pipelining

- Feature de *hardware* para computação paralela;

- As *threads*  $T_1, \dots, T_n$  são organizadas de forma a que uma *thread*  $T_i$  receba como *input* o *output* da *thread*  $T_{i-1}$ ;
- As *threads* utilizadas no *pipelining* poderão ser utilizadas de forma paralela.

## Producer-Consumer

- Os *Producers* geram dados que serão consumidos e processados pelos *Consumers*;
- É utilizado um *buffer* partilhado;
- O *producer* só consegue adicionar dados ao *buffer* se este não estiver cheio;
- O *consumer* só consegue processar dados de um *buffer* não vazio.

## Processos


- Um processo pode ser considerado como a execução de um programa:
  - Contêm toda a informação necessária para a sua execução: dados, *stack*, registos e instruções a serem executadas;
  - Cada processo tem o seu próprio espaço de endereçamento com acesso exclusivo (i.e. nenhum outro processo pode aceder a esta memória).

## Threads

- A criação de *threads* é geralmente mais rápida que a criação de processos;
- As *threads* podem ser fornecidas pelo *runtime* (***user-level threads***) ou pelo SO (***kernel-level threads***):
  - *User-Level Threads*:
    - Correm em qualquer SO;
    - Menos privilégios *low-level*;
    - Não permite que aplicações *multithreaded* corram diferentes *threads* em diferentes processadores;
  - *Kernel-Level Threads*:
    - Gestão ocorre no kernel;

- Permite que o mesmo processo seja escalonado em diferentes *kernel-level threads*;
- Criação e gestão difícil.

## Estados



- **Created:** a *thread* foi criada mas ainda não executou nenhuma operação;
- **Executable:** a *thread* está pronta para ser executada, não estando ainda associada a algum recurso;
- **Running:** a *thread* esta a correr;
- **Waiting:** a *thread* está à espera de um evento externo (i.e. I/O);
- **Finished:** A *thread* terminou a sua execução.

## Controlo de Execução

- **Sincronização por barreira:** define um ponto em que cada *thread* terá que esperar pela execução das restantes;
- **Sincronização por condição:** uma *thread* T1 é bloqueada até que uma certa condição seja cumprida.

## Java

- Estender a classe `Thread` :
  - Mais flexível (permite a utilização de mais métodos);
  - Cada *thread* é uma instância nova da classe que estendeu `Thread` ;
- Implementar a interface `Runnable` :
  - Possui apenas o método `run` ;
  - Útil quando a classe em questão já estende outra classe qualquer.

# Mecanismos de Sincronização

- **Race conditions:**

- Acontecem quando o sistema tenta realizar 2 operações ao mesmo tempo;
- Poderão levar a estados indesejados num *software*.