

# Computação Paralela

```
Tipos de Paralelismo
   Paralelismo por Bit
   Paralelismo por Pipelining
   Paralelismo por Functional Units (FU)
   Paralelismo por Processos ou Threads
Processadores Multicore
   Arquitetura
Conceitos Básicos
Organização de Memória
Execução
Arquiteturas
   Single Instruction, Single Data
   Single Instruction, Multiple Data
   Multiple Instruction, Multiple Data
Implementação
   Modelos
       Modelo Máquina
       Modelo Arquitetural
       Modelo Computacional
       Modelo de Programação
Paralelização de Programas
Padrões
   Fork-Join
   Parbegin-Parend
   SPMD e SIMD
   Master-Slave e Master-Worker
   Client-Server
   Pipelining
   Producer-Consumer
Processos
Threads
   Estados
   Controlo de Execução
```

Java

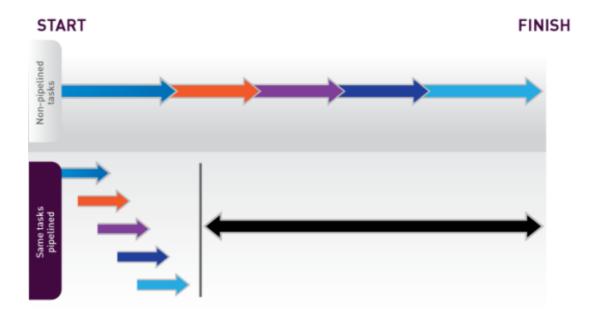
## **Tipos de Paralelismo**

#### Paralelismo por Bit

- Relaciona-se com o aumento na capacidade de processamento de dados;
- Mais bits permitem efetuar operações mais complexas de uma forma mais imediata.

#### **Paralelismo por Pipelining**

- O pipeline pode ser comparado a uma linha de montagem:
  - Cada fase da linha poderá operar em paralelo caso não existam dependências entre as instruções;
  - Um pipeline eficiente possui instruções com durações semelhantes;
  - O throughput de um pipeline é o número de instruções finalizadas por unidade de tempo.



### Paralelismo por *Functional Units* (FU)

- Existem várias unidades funcionais (ALU e FPU) independentes;
  - Estas unidades executam tarefas independente e paralelamente;
  - O número de FU a utilizar paralelamente poderá ser limitado consoante a dependência dos dados;

• A sua utilização irá aumentar significativamente a complexidade do circuito.

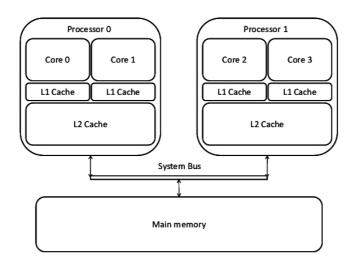
#### Paralelismo por Processos ou *Threads*

- Implica a utilização de sistemas multicore/multiprocessor;
  - Cada core acede à mesma memória partilhada;
  - Cada core executa um só fluxo;
  - o Implica a utilização de técnicas de programação paralelas.

### **Processadores** *Multicore*

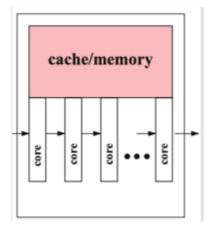
### **Arquitetura**

• **Design hierárquico**: vários cores partilham várias *caches*, organizadas em forma de árvore, com o seu tamanho a aumentar desde as folhas até à raíz;



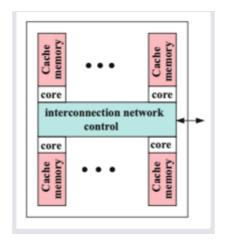
Arquitetura de sistemas multicore.

 Design em pipeline: os dados são processados por elemento sde processamento organizados em formato de pipeline; os dados são transferidos entre os cores de forma sucessiva até deixarem a unidade de processamento.



Arquitetura em pipeline.

• **Design em rede**: os *cores* de um processador e respetivas caches e memórias estão ligadas através de uma rede sob a qual ocorre a transferência de dados.



### **Conceitos Básicos**

- A decomposição da aplicação em tasks é essencial para o design de um sistema paralelo;
  - O tamanho de cada *task* designa-se por **granularidade**;
  - As tasks s\(\tilde{a}\) o programadas atrav\(\tilde{e}\) de processos ou threads, atribu\(\tilde{a}\) dos
    posteriormente a diferentes cores;
    - Scheduling.

## Organização de Memória

• As tasks partilham "conhecimento" de maneiras distintas:

#### Memória Partilhada:

- Pode ser acedida por todos os cores;
- É feita através de R/W em variáveis partilhadas;
  - O acesso a esta memória tem de ser sincronizada.

#### Memória Distribuída:

- Cada processo ou thread tem a sua memória privada;
- A partilha de informação ocorre com a troca de mensagens.

## Execução

- O tempo de execução de um programa paralelo deverá ser menor que a execução das mesmas tarefas de forma sequencial;
- Existirão sempre idle times durante uma execução paralela:
  - O CPU está à espera do output de um evento;
  - Um load balancing equilibrado tenta mitigar os tempos de espera de um programa paralelo: distribuição de tarefas de maneira igual por todos os cores.

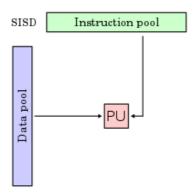
## **Arquiteturas**

### **Single Instruction, Single Data**

A sequential computer which exploits no parallelism in either the instruction or data streams. Single control unit (CU) fetches a single instruction stream (IS) from memory. The CU then generates appropriate control signals to direct a single processing element (PE) to operate on a single data stream (DS) i.e., one operation at a time

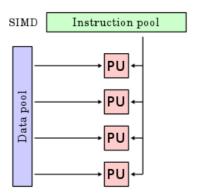
- Computador sequencial que não explora o paralelismo ao nível das instruções nem dos stream de dados:
- Uma única unidade de controlo (control unit, CU) carrega uma única instrução de memória;
- A CU gera os sinais de controlo apropriados para que uma única unidade de processamento (processing element, PE) opere sobre sobre uma único fluxo de

dados (data stream, DS), i..e uma operação de cada vez.

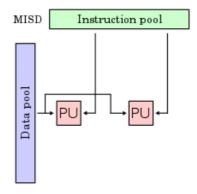


### **Single Instruction, Multiple Data**

- Uma única instrução é simultaneamente aplicada a vários DS;
- As instruções podem ser executadas sequencialmente (e.g. via pipelining ou em parallelo por múltiplas FU).
- Multiple Instruction, Single Data

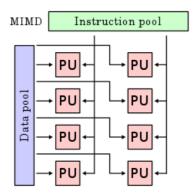


- Várias instruções operam sobre um único fluxo de dados;
- Sistemas deste tipo devem concordar no output/resultado;
- Arquitetura pouco comum, utilizada para tolerância de falhas.



### **Multiple Instruction, Multiple Data**

- Vários CPU autonómos executam, simultaneamente, diferentes instruções em DS diferentes;
- Estas arquiteturas tipicamente incluem sistemas distribuídos.



## Implementação

#### **Modelos**

 Podemos diferenciar os modelos para computação paralela de acordo com o seu nível de abstração.

#### Modelo Máquina

- Descreve o hardware e o SO (e.g. registos e buffers);
- Linguagens assembly usam estes tipos de modelos.

#### **Modelo Arquitetural**

 Descreve ligações entre processos, organização e sincronização de memória, bem como se as instruções são executadas por SIMD ou MIMD.

#### **Modelo Computacional**

- Fornece funções de custo para o tempo necessário para a execução do algoritmo;
- Modelo analítico para o desenho e avaliação de um algoritmo paralelo.

### Modelo de Programação

- Representa a visão de um programador de um determinado sistema paralelo;
- Deverá fornecer um mecanismo para o programador especificar um sistema paralelo: especificar que operações são executadas em paralelo.
  - Como uma sequência de instruções aritméticas ou lógicas;
  - Conjuntos de statements;
  - Uma função ou método que contem diversos statements.

## Paralelização de Programas

- Necessário considerar as estruturas de controlo e dependências de dados;
- Garantir que a versão paralela do programa retorna o mesmo resultado para todos os inputs possíveis;

#### **Padrões**

- Criação de processos e threads:
  - Estaticamente: número fixo de processos ou threads é criado quando o programa é iniciado, e finalizados quando o programa finaliza;
  - Dinamicamente: estes elementos poderão ser criados de forma arbitrária durante a execução do programa.

#### Fork-Join

- Uma thread T cria um conjunto de *threads* filhas  $T_1, \ldots, T_n$ :
  - Trabalham em paralelo e executam uma ou mais instruções/funções.

- ullet T pode executar a mesma parte ou outra qualquer do programa:
- O comando join é utilizado para T esperar pelo resultado de  $T_1, \ldots, T_n$ .

#### **Parbegin-Parend**

- Na construção, são definidas uma série de instruções que deverão ser executadas em paralelo;
- Quando um programa chega a um comando parbegin-parend, um conjunto de threads é criado e as statements são atribuídas às mesmas;
- O restante prorama só é executado depois de todas as threads finalizarem as operações.

#### SPMD e SIMD

- Utilizam um número fixo de threads;
- SIMD: a mesma instrução é executada de forma síncrona por diferentes threads em diferentes conjuntos de dados;
- SPMD: diversas threads trabalham de forma assíncrona entre sí, podendo executar diferentes partes do programa.

#### Master-Slave e Master-Worker

• A *thread* **master** é responsável pela execução do programa (cria *workers* em diferentes partes do programa para realizar operações paralelas).

#### **Client-Server**

- Utilizado em sistemas distribuídos;
- Vários sistemas clientes comunicam com um main-frame que fornece acesso distribuído a uma base de dados;
- Devem ser criadas diversas threads client, que geram algum tipo de pedido ao server.

### **Pipelining**

Feature de hardware para computação paralela;

- As threads  $T_1, \ldots, T_n$  são organizadas de forma a que uma thread  $T_i$  recebe como input o output da thread  $T_{i-1}$ ;
- As threads utilizadas no pipelining poderão ser utilizadas de forma paralela.

#### **Producer-Consumer**

- Os Producers geram dados que serão consumidos e processados pelos Consumers;
- É utilizado um buffer partilhado;
- O producer só conseguem adicionar dados ao buffer se este não estiver cheio;
- O consumer só consegue processar dados de um buffer não vazio.

#### **Processos**

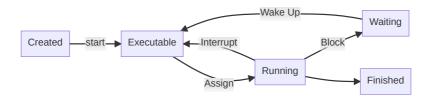
- Um processo pode ser considerado como a execução de um programa:
  - Contêm toda a informação necessária para a sua execução: dados, stack, registos e instruções a serem executadas;
  - Cada processo tem o seu próprio espao de endereçamento co macesso exclusivo (i.e. nenhum outro processo pode aceder a esta memória).

### **Threads**

- A criação de threads é geralmente mais rápid que a criação de processos;
- As threads podem ser fornecidas pelo runtime (user-level threads) ou pelo SO (kernel-level threads):
  - User-Level Threads:
    - Correm em qualquer SO;
    - Menos privilégios low-level;
    - Não permite que aplicações multithreaded corram diferentes threads em diferentes processadores;
  - Kernel-Level Threads:
    - Gestão ocorre no kernel;

- Permite que o mesmo processo seja escalonado em diferentes kernellevel threads;
- Criação e gestão difícil.

#### **Estados**



- Created: a thread foi criada mas ainda não executou nenhuma operação;
- Executable: a thread está pronta para ser executada, não estando ainda associada a algum recurso;
- Running: a thread esta a correr;
- Waiting: a thread está à espera de um evento externo (i.e. I/O);
- Finished: A thread terminou a sua execução.

#### Controlo de Execução

- Sincronização por barreira: define um ponto em que cada thread terá que esperar pela execução das restantes;
- **Sincronização por condição**: uma *thread* T1 é bloqueada até que uma certa condição seja cumprimida.

#### Java

- Estender a classe Thread:
  - Mais flexível (permite a utilização de mais métodos);
  - Cada thread é uma instância nova da classe que estendeu Thread;
- Implementar a interface Runnable:
  - Possui apenas o método run;
  - Útil quando a classe em questão já estende outra classe qualquer.

## Mecanismos de Sincronização

- Race conditions:
  - Acontecem quando o sistema tenta realizar 2 operações ao mesmo tempo;
  - Poderão levar a estados indesejados num software.